Syntax natürlicher Sprachen

10: Probabilistisches Parsing

A. Wisiorek

Centrum für Informations- und Sprachverarbeitung,
Ludwig-Maximilians-Universität München

09.01.2024

1. Erweiterungen von CFG-Grammatiken

1.1. Grammatikentwicklung

Grammatik-Entwicklung

- **Ziel automatischer Syntaxanalyse**:
  $\rightarrow$ *Entwicklung von Grammatik mit hoher* ***Abdeckung/coverage***
  $\rightarrow$ *beschreibungsadäquates* ***Modell der syntaktischen Struktur eines sehr großen Ausschnitts*** *einer natürlichen Sprache*
- **Unifikationsgrammatiken:**
  $\rightarrow$ *modellieren* ***Agreement, Rektion und Subkategorisierung*** *über Merkmalconstraints*
  $\rightarrow$ *Erkennung genau der* ***wohlgeformten Sätze***
  $\rightarrow$ ***beschreibungsadäquate Strukturzuweisung***

Grammatiksysteme

- **von Experten erstellte Grammatik-Systeme**, die den Anspruch haben, einen großen Ausschnitt der Syntax einer natürlichen Sprache abzubilden:
  - Head-Driven Phrase Structure Grammar (**HPSG**):
    $\rightarrow$ ***LinGO Matrix Framework***
    $\rightarrow$ ***delph-in.net*** *(deutsche Grammatik)*
  - Lexical Functional Grammar (**LFG**): **Pargram** Projekt
  - Lexicalized **Tree Adjoining Grammar**: **XTAG** Projekt

Zunahme Ambiguität mit Abdeckung

- **hohe Abdeckung** (viele Regeln, großes Lexikon mit ambigen Einträgen) **und Input langer (komplexer) Sätze** führen zu:
  $\rightarrow$ ***hoher Aufwand beim Parsing***
  $\rightarrow$ ***große Anzahl an Ableitungen/Analysen (Ambiguität)***
- z. B. durch Ambiguität im Lexikon:

  [NP Time] [V flies] like an arrow.

  [V Time] [NP flies] like an arrow.

  [NP Time flies] [V like] an arrow.

1.2. Disambiguierung durch statistische Modelle

Gewichtete Grammatikregeln

- **Erweiterung** von CFGs **um probabilistische Parameter**
  → ***gewichtete Grammatik***: *Produktionsregeln erhalten Bewertung*
  → *erlaubt* ***Ranking der Ableitungen*** *eines strukturell ambigen Satzes aufgrund von* ***Trainingsdaten aus Korpus***
- **Disambiguierung über empirisches Modell**
  → ***statt Disambiguierung über*** *explizite* ***semantische Informationen*** *im Anschluss an syntaktisches Parsing durch semantisches Parsing:*
  → *Auswahl Ableitung aufgrund von* ***statistischen Informationen aus Korpusdaten zu Kollokationen von Wörtern und syntaktischen Kategorien***
  → ***beste syntaktische Analyse*** *eines Satzes* **= *die im Sprachgebrauch häufigste***
  → ***graduelle Modellierung von Grammatikalität***

Disambiguierung über PCFGs I

- **Probabilistische CFG (= PCFG)** erlaubt in Kombination mit **dynamischem Parsing** das effiziente Auffinden der besten (= wahrscheinlichsten) Ableitung
- **ohne Gewichtung**: dynamische Programmierung (CYK, Earley) kann zwar Parsing-Aufwand bei großem Suchraum (großer Grammatik) reduzieren, aber **keine Auswahl** treffen aus den gefundenen Ableitungen
- **statistische Informationen** können auch **im Parsing von Unfikationsgrammatiken** (wie LFG, HPSG) zur Disambiguierung verwendet werden
- **nächste Sitzung:** statt bloßer Erweiterung einer gegebenen CFG um statistische Informationen aus Treebanks: **Extraktion von Grammatiken aus Treebanks**
  $\rightarrow$ *in solchen **induzierten Grammatiken** können auch **lexikalische Informationen und Informationen zum strukturellen Kontext** berücksichtigt werden, die der weiteren **Disambiguierung** dienen*

Disambiguierung über PCFGs II

- Erweiterung von CFG-Grammatiken durch statistische Parameter zur **Disambiguierung**
- **strukturelle Disambiguierung** durch *parse selection* (Herausfiltern der wahrscheinlichsten Ableitung)
- **Wahrscheinlichkeiten der Regeln** müssen anhand von Korpusdaten gelernt werden (Parameter-Abschätzung)
- Algorithmen dynamischer Programmierung (**Viterbi-Algorithmus**) zur **effizienten Auffindung der wahrscheinlichsten Ableitung**

2. PCFGs: Probabilistische kontextfreie Grammatiken

1. Erweiterungen von CFG-Grammatiken
   - Grammatikentwicklung
   - Disambiguierung durch statistische Modelle

2. PCFGs: Probabilistische kontextfreie Grammatiken
   - PCFG: Definitionen
   - Abschätzung der Regelwahrscheinlichkeiten

3. Probabilistische CFG-Parsing-Algorithmen

Literatur:

- **MS**: Manning, Christopher D. & Schütze, Hinrich (1999): *Foundations of Statistical Natural Language Processing*.
- NLTK-Teilkapitel 8.6 ('*Grammar Development*') und 8.5.2 ('*Scaling up*'): `http://www.nltk.org/book/ch08.html`
- Teilkapitel 2.12 ('*Grammar Induction*') des Zusatzkapitels zu Kapitel 8: `http://www.nltk.org/book/ch08-extras.html`
- Die Teilkapitel 2.9-2.11 des Zusatzkapitels zu Kapitel 8 behandeln probabilistische Chart Parsing-Algorithmen: `http://www.nltk.org/book/ch08-extras.html`

2.1. PCFG: Definitionen

1. Erweiterungen von CFG-Grammatiken
   - Grammatikentwicklung
   - Disambiguierung durch statistische Modelle
2. PCFGs: Probabilistische kontextfreie Grammatiken
   - PCFG: Definitionen
   - Abschätzung der Regelwahrscheinlichkeiten
3. Probabilistische CFG-Parsing-Algorithmen

PCFG I

- **PCFG** = kontextfreie Grammatik, deren Regeln mit **Wahrscheinlichkeiten** gewichtet sind:
  $S \rightarrow NP\ VP\ \ 1.0$
  $VP \rightarrow VP\ NP\ \ 0.4$
  $VP \rightarrow VP\ NP\ PP\ \ 0.6$
  $NP \rightarrow NP\ PP\ \ 0.2$
  $NP \rightarrow N\ \ 0.8$
- **Wahrscheinlichkeiten** aller Regeln **für die Expansion eines bestimmten Nonterminals** addieren sich zu **1**

PCFG II

- **Ableitung/Baum** ist **Menge an Regeln/Expansionen**
  $\rightarrow$ *Teilbäume mit Tiefe 1*
- **Wahrscheinlichkeit einer Ableitung T** $(Tree)$ als Multiplikation der Wahrscheinlichkeiten ihrer Regeln:

$$P(T) = \prod_{i=1}^{n} P(R_i) = \prod_{i=1}^{n} P(RHS_i|LHS_i)$$

$\rightarrow$ *Iteration über die n Knoten im Baum:* ***Produkt der Wahrscheinlichkeit der Expansion des LHS-Knotens von*** R_i ***zu RHS-Smbolfolge von*** R_i
$\rightarrow$ ***Annahme Unabhängigkeit der Regel-Auswahl***

Wahrscheinlichste Ableitung

- zur **Disambiguierung** muss die **wahrscheinlichste Ableitung T*** zu einem Satz S gefunden werden:
  - $T^* = arg\ max\ P(T|S) = arg\ max \frac{P(T,S)}{P(S)} = arg\ max\ \frac{P(T)}{P(S)}$
    $(P(T,S) = P(T)P(S|T), P(S|T) = 1; \textit{jeder Baum leitet genau einen Satz ab})$
  - $T^* = arg\ max\ P(T)$
    $(\textit{da } P(S) \textit{ konstant fuer ein } S, \textit{ also irrelevant fuer Auswahl Ableitung zu gegebenem Satz})$
- **Satzwahrscheinlichkeit**: Summe der Wahrscheinlichkeiten aller möglichen Ableitungen eines Satzes:
  $P(S) = \sum P(T,S) = \sum P(T)$

Beispiel-PCFG PP-Attachment-Ambiguität

$S \rightarrow NP\ VP\ \ 1$
$PP \rightarrow P\ NP\ \ 1$
$NP \rightarrow DET\ N\ \ 0.5$
$NP \rightarrow PRON\ \ 0.3$
$NP \rightarrow NP\ PP\ 0.2$
$VP \rightarrow V\ \ 0.1$
$VP \rightarrow V\ NP\ \ 0.3$
$VP \rightarrow VP\ PP\ \ 0.6$

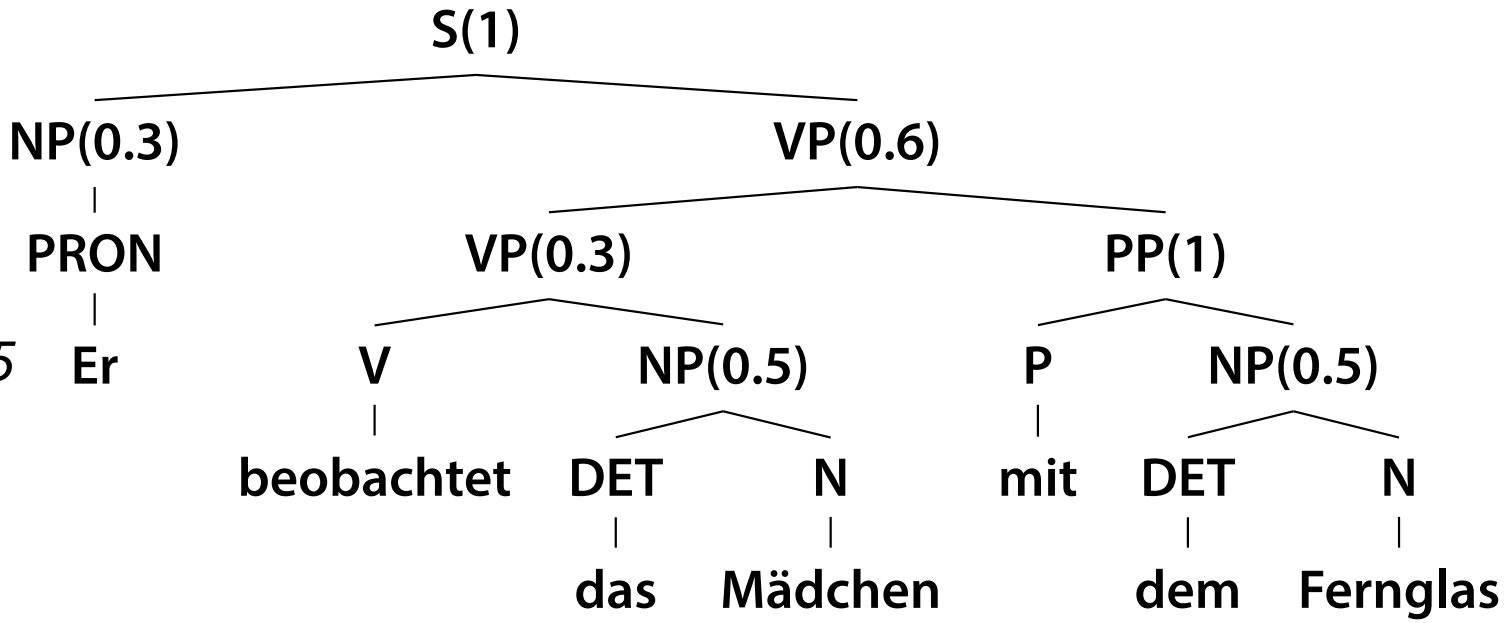

$P(T_1) = 1 * 0.3 *$ **0.6** $*$ **0.3** $* 0.5 * 1 * 0.5 =$ **0.0135** (ohne lexikalische Gewichte, diese sind konstant für einen Satz)

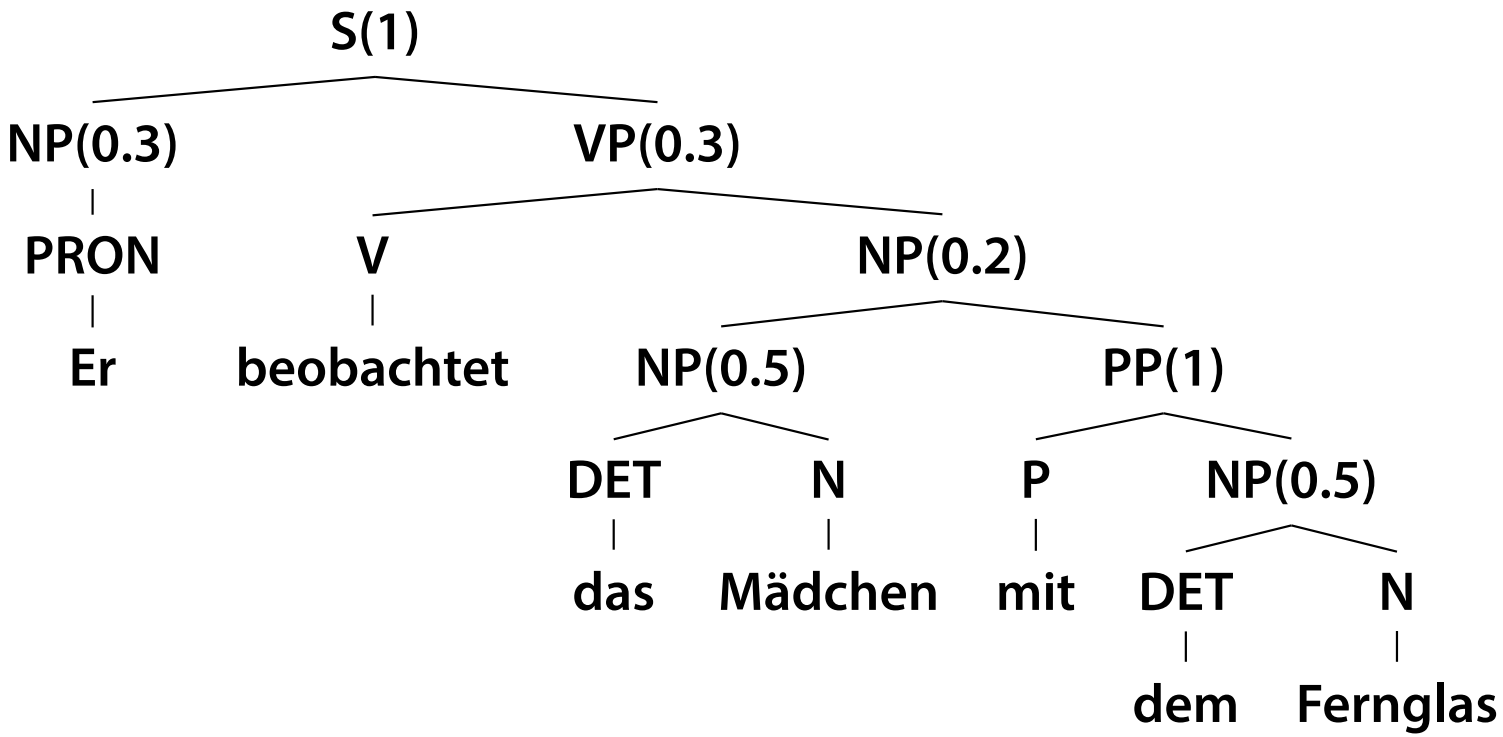

$P(T_2) = 1 * 0.3 * \mathbf{0.3} * \mathbf{0.2} * 0.5 * 1 * 0.5 = \mathbf{0.0045}$

$\Rightarrow$ **Auswahl adverbialer Lesart** : $P(T_1) > P(T_2)$
Grund: $P(VP, PP|VP) > P(NP, PP|NP)$

2.2. Abschätzung der Regelwahrscheinlichkeiten

1. Erweiterungen von CFG-Grammatiken
   - Grammatikentwicklung
   - Disambiguierung durch statistische Modelle
2. PCFGs: Probabilistische kontextfreie Grammatiken
   - PCFG: Definitionen
   - Abschätzung der Regelwahrscheinlichkeiten
3. Probabilistische CFG-Parsing-Algorithmen

Zwei Methoden für Abschätzung

- ***supervised*** = Bestimmung der relativen Häufigkeiten der Expansionen eines Nichtterminals in geparstem (syntaktisch annotiertem) Korpus (**Maximum Likelihood Estimation**)
- ***unsupervised*** = wiederholtes Parsen von Korpus mit der gegebenen kontextfreien Grammatik und sukzessive Verbesserung eines statistischen Modells (**Inside-Outside-Algorithmus**)

1. *Maximum Likelihood Estimation* (MLE)

- Abschätzung der Regelwahrscheinlichkeit als **relative Häufigkeit der Expansion des LHS-Nonterminals zu RHS-Symbolfolge in Treebank** (syntaktisch annotiertem Korpus)
- $P(\alpha \rightarrow \beta|\alpha) = \frac{count(\alpha \rightarrow \beta)}{\sum_\gamma count(\alpha \rightarrow \gamma)} = \frac{count(\alpha \rightarrow \beta)}{count(\alpha)}$
- **Expansionswahrscheinlichkeit:**
  $P(RHS|LHS) = P(Expansion|Nonterminal)$
  $\rightarrow$ *Idee: gute probabilistische Grammatik* ***maximiert die Wahrscheinlichkeit der Trainingsdaten***

Beispiel: MLE

- Wahrscheinlichkeit für Expansion $VP \rightarrow V\ NP\ PP$:

$$P(V, NP, PP|VP) = \frac{count(VP \rightarrow V\ NP\ PP)}{count(VP \rightarrow \backslash *)}$$

- $count(VP \rightarrow V\ NP\ PP) = 10$
  $count(VP \rightarrow V\ NP) = 50$
  $count(VP \rightarrow V) = 40$
  $\Rightarrow MLE(VP \rightarrow V\ NP\ PP \mid VP) = 1/10$

2. Inside-Outside-Algorithmus

- Abschätzung der Regelwahrscheinlichkeiten auch **ohne syntaktisch annotiertes Trainingskorpus**, d. h. ***unsupervised*** möglich mit **Inside-Outside-Algorithmus**
- Variante von **EM-Algorithmus** (*Expectation-Maximation*)
  $\rightarrow$ ***iterativen Abschätzung der Regelwahrscheinlichkeiten*** *(als Parameter des statistischen Modells)*
  $\rightarrow$ ***Übertragung des Forward-Backward-Algorithmus*** *(zur Abschätzung von Parametern bei HMMs) auf PCFGs*

3. Probabilistische CFG-Parsing-Algorithmen

1. Erweiterungen von CFG-Grammatiken
   - Grammatikentwicklung
   - Disambiguierung durch statistische Modelle
2. PCFGs: Probabilistische kontextfreie Grammatiken
   - PCFG: Definitionen
   - Abschätzung der Regelwahrscheinlichkeiten
3. Probabilistische CFG-Parsing-Algorithmen

Probabilistisches Parsing

- **Suche der wahrscheinlichsten Ableitung**:
  $arg\ max\ P(T|S) = arg\ max\ P(T)$
- **Suche aller Ableitungen** und Berechnung ihrer Wahrscheinlichkeiten wird **bei großen Grammatiken sehr aufwendig**
- besser: **probabilistische Varianten von Chart-Parsing-Algorithmen** wie CYK- oder Earley-Algorithmus
- Verwendung statistischer Informationen in **dynamischer Programmierung** zum effizienten Auffinden der wahrscheinlichsten (Teil)bäume

Viterbi-Parser I

- **PCFG-Version des Viterbi-Algorithmus** (analog zu HMM): **Finden der wahrscheinlichsten verborgenen Zustandsfolge**
  (*Ableitung T*), die die beobachtete Sequenz emitiert (*Satz S*)
  $\rightarrow$ *Bestimmung des* ***wahrscheinlichsten Baumes*** *durch Zurückgreifen* ***auf berechnete Teilbäume***
  $\rightarrow$ *die* ***Wahrscheinlichkeit größerer*** *Teilbäume ergibt sich* ***aus den Wahrscheinlichkeiten der kleineren****, da aufgrund der Kontextfreiheit die Wahrscheinlichkeit eines Teilbaums unabhängig von seiner Position ist*
  $\rightarrow$ ***nur die Teilbäume mit höchster Wahrscheinlichkeit*** *werden behalten und zur Berechnung verwendet*
- **Performanz-Optimierung** des Parsings durch Verwendung statistischer Informationen
  $\rightarrow$ *statt allen möglichen* ***nur die wahrscheinlichsten Teilergebnisse verwenden***

Viterbi-Parser II

- `nltk.ViterbiParser`
  $\rightarrow$ ***Bottom-up-PCFG-Parser***
  $\rightarrow$ *berechnet inkrementell (beginnend mit Spanne Länge 1) die* ***wahrscheinlichsten (Teil)bäume*** *durch Ausfüllen einer* ***'Most Likely Constituents Table'***
- für **gegebene Spanne** und **Knoten-Wert** (LHS einer Regel):
  $\rightarrow$ *Suche nach* ***Folgen von Tabellen-Einträgen****, die gemeinsam die* ***Spanne abdecken***
  $\rightarrow$ *Überprüfung, ob* ***Tabellen-Einträge die RHS-Werte der Regel als Knotenwerte*** *haben (LHS der Tabellen-Einträge)*

Span	Node	Tree
$[0:1]$	NP	(NP I)
$[6:7]$	NP	(NN telescope)
$[5:7]$	NP	(NP the telescope)
$[4:7]$	PP	(PP with (NP the telescope))
$[0:4]$	S	(S (NP I) (VP saw (NP the man)))
$[0:7]$	S	(S (NP I) (VP saw (NP (NP the man) (PP with (NP the telescope)))))

Abbildung: Most Likely Constituents Table (Ausschnitt)

- Tabelle enthält **nur die wahrscheinlichste Ableitung für eine Spanne und Knoten-Wert**: z. B. wird nur die *NP-attachment*-Variante für Spanne $[1:7]$ und Knoten-Wert VP aufgenommen:

$[1:7]$	VP	(VP saw (NP (NP the man) (PP with (NP the telescope))))
$[1:7]$	VP	(VP saw (NP (NP the man)) (PP with (NP the telescope)))

Listing 1: NLTK: PCFG-Parsing mit Viterbi-Parser

```
1  #http://www.nltk.org/_modules/nltk/parse/viterbi.html
2  #http://www.nltk.org/book/ch08-extras.html
3
4  grammar = nltk.PCFG.fromstring('''
5    NP  -> NNS [0.5] | JJ NNS [0.3] | NP CC NP [0.2]
6    NNS -> "cats" [0.1] | "dogs" [0.2] | "mice" [0.3] |
         NNS CC NNS [0.4]
7    JJ  -> "big" [0.4] | "small" [0.6]
8    CC  -> "and" [0.9] | "or" [0.1]
9    ''')
10
11 sent = 'big cats and dogs'.split()
12
13 viterbi_parser = nltk.ViterbiParser(grammar)
14 for tree in viterbi_parser.parse(sent):
15     print(tree)
16 #(NP (JJ big) (NNS (NNS cats) (CC and) (NNS dogs))) (p
     =0.000864)
17
18 viterbi_parser.trace(3)
```

```
19 for tree in viterbi_parser.parse(sent):
20     print(tree)
21
22
23 #Inserting tokens into the most likely constituents
       table...
24 #    Insert: |=...| big
25 #    Insert: |.=..| cats
26 #    Insert: |..=.| and
27 #    Insert: |...=| dogs
28 #Finding the most likely constituents spanning 1 text
       elements...
29 #    Insert: |=...| JJ -> 'big' [0.4]
       0.4000000000
30 #    Insert: |.=..| NNS -> 'cats' [0.1]
       0.1000000000
31 #    Insert: |.=..| NP -> NNS [0.5]
       0.0500000000
32 #    Insert: |..=.| CC -> 'and' [0.9]
       0.9000000000
33 #    Insert: |...=| NNS -> 'dogs' [0.2]
```

```
    0.2000000000
#    Insert: |...=| NP -> NNS [0.5]
    0.1000000000

#Finding the most likely constituents spanning 2 text
    elements...
#    Insert: |==..| NP -> JJ NNS [0.3]
    0.0120000000
#Finding the most likely constituents spanning 3 text
    elements...
#    Insert: |.===| NP -> NP CC NP [0.2]
    0.0009000000
#    Insert: |.===| NNS -> NNS CC NNS [0.4]
    0.0072000000
#    Insert: |.===| NP -> NNS [0.5]
    0.0036000000
#   Discard: |.===| NP -> NP CC NP [0.2]
    0.0009000000
#   Discard: |.===| NP -> NP CC NP [0.2]
    0.0009000000
```

```
45 #Finding the most likely constituents spanning 4 text
       elements...
46 #    Insert: |====| NP -> JJ NNS [0.3]
       0.0008640000
47 #   Discard: |====| NP -> NP CC NP [0.2]
       0.0002160000
48 #   Discard: |====| NP -> NP CC NP [0.2]
       0.0002160000
49 #(NP (JJ big) (NNS (NNS cats) (CC and) (NNS dogs))) (p
       =0.000864)
```

Probabilistische Chart-Parser

- `nltk.parse.pchart` = **Klasse von Bottom-up-PCFG-Chart-Parsern**
- **Chart-Parsing mit zusätzlicher Datenstruktur *edge queue***, deren **Sortierung** die Reihenfolge der Abarbeitung der Zustände festlegt
  $\rightarrow$ ***edge*** *in Chart-Parsing nach Kay* = ***Zustand*** *bei Earley/CYK*
- im Gegensatz zu Viterbi-Parser wird **nicht nur die wahrscheinlichste Ableitung** gefunden, sondern die **n-besten Ableitungen**
- Verwendung von **statistischen Daten zur Sortierung**

Strategien zur Sortierung des *edge queues*

- **Lowest Cost First** = `nltk.InsideChartParser`
  → ***Sortierung nach Wahrscheinlichkeit*** *der Ableitungen*
  → *findet immer die* ***optimale*** *Lösung (wahrscheinlichste Ableitung)*
  → ***Problem: kürzere Teilergebnisse haben üblicherweise eine höhere Wahrscheinlichkeit*** *(P = Produkt der Regelwahrscheinlichkeiten) und werden so zuerst abgearbeitet;* ***vollständige Ableitung wird erst spät produziert***
- **Best-First Search** = `nltk.LongestChartParser`
  → ***Sortierung nach Länge*** *(für vollständige Ableitung: längste Spanne gesucht)*
  → *i. A.* ***schneller*** *als Lowest Cost First*
  → *garantiert nicht, dass optimale Ableitung gefunden wird*

- **Beam Search (Pruning)** = `nltk.InsideChartParser(grammar, beam_size=20)`
  → *Lowest-Cost-First, aber **nur die n-besten partiellen Ergebnisse behalten** (= Pruning)*
  → ***schneller** als Lowest-Cost-First ohne Pruning*
  → *garantiert nicht, dass optimale Ableitung gefunden wird*
  → *garantiert nicht, dass überhaupt eine Ableitung gefunden wird (wenn notwendige edges fehlen)*

Listing 2: NLTK: PCFG-Parsing mit ChartParser

```
1  #http://www.nltk.org/_modules/nltk/parse/pchart.html
2  #http://www.nltk.org/book/ch08-extras.html
3
4  inside_parser = nltk.InsideChartParser(grammar)
5  longest_parser = nltk.LongestChartParser(grammar)
6  beam_parser = nltk.InsideChartParser(grammar, beam_size
       =20)
7
8  for tree in inside_parser.parse(sent):
9      print(tree)
10 #(NP (JJ big) (NNS (NNS cats) (CC and) (NNS dogs))) (p
       =0.000864)
11 #(NP (NP (JJ big) (NNS cats)) (CC and) (NP (NNS dogs)))
       (p=0.000216)
```